

AI 차량 점검 리포트 시스템

최종 실험 보고서

차량 센서 데이터와 정비/예지정비 데이터를 대상으로 `데이터 전처리 -> 머신러닝 학습 -> 새 데이터 적용 -> 결과 도출` 흐름을 재실험하고, 성능 지표와 시각적 결과물을 최종 정리했다.

프로젝트 경로 /home/ktj/Machine_Learning_Project		보고서 생성일 2026-06-05		
재실험 명령 run_mendeley_experiment.py + run_additional_experiments.py		포함 그래프 20개 figure		
0.965 OBD/CAN Macro F1	0.818 Mendeley Macro F1	0.791 Maintenance Macro F1	0.496 AI4I Macro F1	0.420 KIT OBD-II Macro F1
최종 결론 가장 안정적인 결과는 OBD-II/CAN 운전 습관 실험이며, Macro F1은 0.965이다. 실제 차량/센서 데이터 중심 실험은 Mendeley, OBD-II/CAN, KIT Automotive OBD-II이고, Vehicle Maintenance와 AI4I는 정비/예지정비 구조 검증을 위한 합성 보조 benchmark로 해석해야 한다.				

1. 프로젝트 개요

본 프로젝트는 차량 주행 습관과 차량 상태를 분석해 점검 리포트를 만드는 머신러닝 파이프라인이다. 핵심은 raw 데이터 확보 이후 feature schema를 통일하고, 학습된 기준을 새 데이터에 적용해 분류 또는 이상 탐지 결과를 산출하는 것이다.

최종 성능 요약

실험	데이터 성격	모델	Train/Test	Accuracy	Macro F1	정답/전체
Mendeley 스마트폰 센서	실제 주행 스마트폰 센서	standardized k-NN	10,687 / 3,562	0.826	0.818	2,942 / 3,562
OBD-II/CAN 운전 습관	실제/공개 OBD-II & CAN 차량 내부 신호	standardized class-centroid	416,251 / 138,749	0.976	0.965	135,462 / 138,749
Vehicle Maintenance 이상 탐지	합성 차량 telemetry	robust z-score anomaly detector	1,479 / 491	0.978	0.791	480 / 491
KIT Automotive OBD-II	실제 OBD-II trip 로그	standardized class-centroid	62 / 19	0.526	0.420	10 / 19
AI4I 예지정비	합성 예지정비 benchmark	standardized class-centroid	7,501 / 2,499	0.726	0.496	1,815 / 2,499

합성 데이터 사용 고지

Vehicle Maintenance Telemetry와 AI4I 2020은 데이터셋 자체가 합성이다. 최종 보고서에서는 실제 차량/센서 데이터 실험과 합성 보조 benchmark를 분리해 해석한다. 내부 demo용 `simulated\_trip\_features.csv`는 최종 추가 실험에는 사용하지 않았다.

2. 전처리와 머신러닝 적용 방식

전처리 공통 흐름

- CSV/ZIP/TAR로 확보한 raw 데이터를 데이터셋별 loader로 읽는다.
- 필요 컬럼을 프로젝트 표준 feature명으로 매핑한다.
- 센서값을 수치형으로 변환하고 필수 feature와 라벨 결측행을 제거한다.
- 데이터셋별 라벨을 모델 target으로 재정의한다.
- 라벨 비율을 보존하는 75/25 stratified split을 적용한다.
- confusion matrix, class별 F1, feature importance, feature distribution을 생성한다.

머신러닝 알고리즘 사용 지점

- **standardized k-NN**: Mendeley 센서 행을 표준화한 뒤 가까운 학습 샘플 다수결로 운전 습관을 분류한다.
- **standardized class-centroid**: 클래스별 평균 feature 벡터를 학습하고, 새 데이터가 가장 가까운 클래스 중심으로 분류된다.
- **robust z-score anomaly detector**: 정상 정비 telemetry의 median/MAD 기준을 학습하고 정상 범위 이탈을 issue로 판정한다.
- **feature importance**: 클래스 간 분산 비율을 기반으로 어떤 feature가 라벨 구분에 중요한지 해석한다.

Mendeley 스마트폰 센서

스마트폰 센서만으로 주행 습관을 분류하는 기준선 실험이다. k-NN은 표준화된 센서 feature 공간에서 가까운 학습 샘플의 라벨을 사용해 새 데이터를 분류한다.

0.826 Accuracy	0.818 Macro F1	10,687 Train rows	3,562 Test rows
-------------------	-------------------	----------------------	--------------------

데이터와 전처리

- 데이터 성격: 실제 주행 스마트폰 센서
- 목표 task: normal/aggressive 운전 습관 분류
- 라벨 분포: normal: 5,805, aggressive: 8,444
- 모델: standardized k-NN
- 가속도/자이로 컬럼을 수치형으로 변환하고 결측 행 제거
- label 0/1을 normal/aggressive로 매핑
- 축별 절댓값과 acc/gyro magnitude 파생 feature 생성
- 라벨 비율을 보존한 75/25 stratified split 적용

Class별 성능

Class	Precision	Recall	F1	Support
normal	0.800	0.763	0.781	1,451
aggressive	0.842	0.869	0.855	2,111



Confusion Matrix


actual \ predicted	normal	aggressive
normal	1,107	344
aggressive	276	1,835

Top Feature Importance


Feature	Importance
acc_magnitude	0.178
gyro_magnitude	0.167
acc_abs_x	0.124
gyro_abs_x	0.123
acc_abs_y	0.114

시각적 결과물





F1 Scores



Sensor Distribution

OBD-II/CAN 운전 습관

차량 내부 신호 기반 실험이다. 클래스별 평균 벡터를 학습한 뒤 새 데이터가 어느 클래스 중심에 가까운지로 주행 습관을 판정한다.

0.976 Accuracy	0.965 Macro F1	416,251 Train rows	138,749 Test rows
-------------------	-------------------	-----------------------	----------------------

데이터와 전처리

- 데이터 성격: 실제/공개 OBD-II & CAN 차량 내부 신호
- 목표 task: moderate/aggressive 운전 습관 분류
- 라벨 분포: moderate: 436,602, aggressive: 118,398
- 모델: standardized class-centroid
- 스페인어 원본 컬럼명을 프로젝트 표준 feature명으로 매핑
- 배터리 전압, 엔진 부하, 냉각수 온도, RPM, 속도, throttle 등 수치형 변환
- 원본 Label 0은 aggressive, Label 1은 moderate로 재정의
- 라벨 비율을 보존한 75/25 stratified split 적용

Class별 성능

Class	Precision	Recall	F1	Support
moderate	0.988	0.982	0.985	109,150
aggressive	0.935	0.956	0.945	29,599


Confusion Matrix

actual \ predicted	moderate	aggressive
moderate	107,168	1,982
aggressive	1,305	28,294


Top Feature Importance

Feature	Importance
relative_throttle_position	0.179
accelerator_pedal_d	0.155
accelerator_pedal_e	0.155
throttle_position	0.154
intake_pressure	0.144


시각적 결과물




Confusion Matrix



Feature Importance



F1 Scores



Feature Distribution

Vehicle Maintenance 이상 탐지

정상 차량 상태의 robust 기준을 학습하고, 새 telemetry가 정상 범위를 벗어나는지 보는 이상 탐지 실험이다. 고장 데이터가 적기 때문에 issue recall을 중요하게 본다.

합성 데이터 고지

이 실험 데이터셋은 실제 차량 운행 로그가 아니라 합성/벤치마크 성격의 데이터다. 따라서 모델 구조 검증과 보조 비교용으로 해석한다.

0.978 Accuracy	0.791 Macro F1	1,479 Train rows	491 Test rows
-------------------	-------------------	---------------------	------------------

데이터와 전처리

- 데이터 성격: 합성 차량 telemetry
- 목표 task: normal/issue 차량 상태 판정
- 라벨 분포: normal: 1,935, issue: 35
- 모델: robust z-score anomaly detector
- 이상 탐지 threshold: 0.123
- 정비 telemetry 컬럼을 수치형으로 변환하고 필수 feature 결측 제거
- failure_type 및 engine/brake/battery issue flag를 issue_label로 통합
- 정상 데이터만 사용해 median/MAD 기반 정상 범위 학습
- 테스트 데이터의 robust z-score 평균이 threshold 이상이면 issue로 판정

Class별 성능

Class	Precision	Recall	F1	Support
normal	1.000	0.977	0.988	483
issue	0.421	1.000	0.593	8


Confusion Matrix

actual \ predicted	normal	issue
normal	472	11
issue	0	8


Top Feature Importance

Feature	Importance
battery_voltage_v	0.275
brake_temp_c	0.254
brake_fluid_level_psi	0.243
battery_current_a	0.093
vibration_level	0.051


시각적 결과물




Confusion Matrix



Feature Importance



F1 Scores



Feature Distribution

KIT Automotive OBD-II

row-level OBD 로그를 trip-level feature로 변환하는 검증 실험이다. 데이터 수가 81개로 작아 성능보다 전처리 구조 검증 의미가 크다.

0.526 Accuracy	0.420 Macro F1	62 Train rows	19 Test rows
-------------------	-------------------	------------------	-----------------

데이터와 전처리

- 데이터 성격: 실제 OBD-II trip 로그
- 목표 task: normal/free_flow/traffic 도로 조건 분류
- 라벨 분포: normal: 56, free_flow: 14, traffic: 11
- 모델: standardized class-centroid
- 81개 CSV 주행 로그를 파일 단위 trip으로 집계
- 파일명에서 Normal/Frei/Stau 라벨을 추출해 road_condition 생성
- RPM, 속도, throttle, pedal, 냉각수 온도 등의 mean/max/std/ratio feature 생성
- trip 수가 작아 결과 해석 시 데이터 부족을 함께 고려

Class별 성능

Class	Precision	Recall	F1	Support
normal	0.727	0.571	0.640	14
free_flow	0.333	0.333	0.333	3
traffic	0.200	0.500	0.286	2


Confusion Matrix

actual \ predicted	normal	free_flow	traffic
normal	8	2	4
free_flow	2	1	0
traffic	1	0	1


Top Feature Importance

Feature	Importance
coolant_temp_mean	0.152
pedal_e_max	0.104
pedal_d_max	0.104
rpm_mean	0.078
speed_mean	0.066


시각적 결과물




Confusion Matrix



Feature Importance



F1 Scores



Feature Distribution

AI4I 예지정비

차량 데이터는 아니지만 예지정비 문제 구조를 보조 검증하는 benchmark다. failure class가 적어 class별 F1과 confusion matrix가 중요하다.

합성 데이터 고지

이 실험 데이터셋은 실제 차량 운행 로그가 아니라 합성/벤치마크 성격의 데이터다. 따라서 모델 구조 검증과 보조 비교용으로 해석한다.

0.726 Accuracy	0.496 Macro F1	7,501 Train rows	2,499 Test rows
-------------------	-------------------	---------------------	--------------------

데이터와 전처리

- 데이터 성격: 합성 예지정비 benchmark
- 목표 task: normal/failure 고장 여부 분류
- 라벨 분포: normal: 9,661, failure: 339
- 모델: standardized class-centroid
- 온도, 회전 속도, 토크, 마모 feature를 수치형으로 변환
- Machine failure 0/1을 normal/failure로 매핑
- Type H/L/M을 one-hot feature로 변환
- 라벨 불균형을 고려해 Accuracy와 Macro F1을 함께 평가

Class별 성능

Class	Precision	Recall	F1	Support
normal	0.988	0.725	0.837	2,415
failure	0.087	0.750	0.156	84


Confusion Matrix

actual \ predicted	normal	failure
normal	1,752	663
failure	21	63


Top Feature Importance

Feature	Importance
torque_nm	0.638
tool_wear_min	0.128
air_temperature_k	0.121
rotational_speed_rpm	0.035
process_temperature_k	0.029


시각적 결과물




Confusion Matrix



Feature Importance



F1 Scores



Feature Distribution

8. 최종 결론과 한계

결론

- OBD-II/CAN 실험은 Macro F1 0.965로 가장 안정적인 실제 차량 내부 신호 기반 분류 결과를 보였다.
- Mendeley 실험은 스마트폰 센서만으로도 Macro F1 0.818의 주행 습관 분류 기준선을 제공했다.
- Vehicle Maintenance 실험은 issue를 놓치지 않는 이상 탐지 구조를 보여줬지만 합성 telemetry 데이터임을 명확히 해야 한다.
- KIT Automotive OBD-II는 실제 trip 로그 기반이지만 trip 수가 81개로 작아 추가 데이터 확보가 필요하다.
- AI4I는 예지정비 구조를 보조 검증하는 합성 benchmark이며, failure class 불균형 때문에 Macro F1이 낮게 나타났다.

다음 단계

- 정비/고장 예측 파트는 실제 차량 정비 이력 또는 실제 fleet telemetry 데이터로 교체한다.
- KIT OBD-II는 trip 수를 늘리거나 다른 실제 OBD-II 데이터셋을 추가해 다중 클래스 분류 성능을 재평가한다.
- 현재 baseline 모델에 RandomForest, Gradient Boosting, IsolationForest 등 비교 모델을 추가한다.
- 시계열 특성이 강한 데이터에는 window 기반 feature 또는 sequence 모델을 별도 실험한다.